

TP final de Regresión Avanzada

Martín Ceriotti

2026-04-29

Consigna I: Regresión Lineal

Modelo 1:

Modelo de Selección Automática por Criterio de Información de Akaike (AIC). Se busca equilibrio entre bondad de ajuste y complejidad.

Summary del Modelo 1:

Tabla 1: Coeficientes del Modelo AIC

Término	Estimación	Error Est.	Estadístico t	p-valor
(Intercept)	-31.39	80.12	-0.39	6.95e-01
formalSi	301.37	18.74	16.08	4.34e-57
horas_trabajo	10.69	0.51	21.08	1.88e-95
educ_catPrimario	103.33	57.91	1.78	7.44e-02
educ_catSecundario	237.63	57.30	4.15	3.41e-05
educ_catSuperior	606.55	58.63	10.35	6.90e-25
regionGran Buenos Aires	139.12	31.03	4.48	7.46e-06
regionNoreste	-138.26	35.81	-3.86	1.14e-04
regionNoroeste	-135.49	27.32	-4.96	7.28e-07
regionPampeana	92.24	27.12	3.40	6.75e-04
regionPatagonia	372.13	31.40	11.85	4.53e-32
edad	4.41	0.77	5.74	9.63e-09
sexoMujer	-152.07	16.04	-9.48	3.50e-21
est_civilseparado o divorciado	-119.81	30.62	-3.91	9.24e-05
est_civilsoltero	-137.89	21.78	-6.33	2.61e-10
est_civilunido	-63.01	20.97	-3.00	2.67e-03
est_civilviudo	-183.93	64.60	-2.85	4.42e-03
ant_laborall a 5 años	-23.98	38.66	-0.62	5.35e-01

Término	Estimación	Error Est.	Estadístico t	p-valor
ant_laboral6 meses a 1 año	-81.54	49.31	-1.65	9.82e-02
ant_laboralEntre 3 y 6 meses	-52.46	52.69	-1.00	3.19e-01
ant_laboralMas de 5 años	43.69	39.92	1.09	2.74e-01
ant_laboralMenos de 1 mes	-92.42	84.89	-1.09	2.76e-01

Tabla 2: Estadísticos de Ajuste del Modelo

R-squared	Adj. R-squared	Sigma (Res. Error)	F-statistic	p-value	DF
0.33	0.327	582.379	149.845	0	6402

Modelo 2:

Modelo de Selección Automática por Criterio de Información Bayesiano (BIC). Este modelo se seleccionó bajo el principio de parsimonia.

Summary del Modelo 2:

Tabla 3: Coeficientes del Modelo BIC

Término	Estimación	Error Est.	Estadístico t	p-valor
(Intercept)	-96.01	72.84	-1.32	1.88e-01
formalSi	325.31	17.70	18.38	1.48e-73
horas_trabajo	10.68	0.51	21.09	1.67e-95
educ_catPrimario	114.44	57.82	1.98	4.78e-02
educ_catSecundario	249.28	57.21	4.36	1.34e-05
educ_catSuperior	618.68	58.51	10.57	6.49e-26
regionGran Buenos Aires	135.21	31.05	4.35	1.36e-05
regionNoreste	-134.97	35.84	-3.77	1.67e-04
regionNoroeste	-134.54	27.35	-4.92	8.93e-07
regionPampeana	89.02	27.13	3.28	1.04e-03
regionPatagonia	370.22	31.42	11.78	1.03e-31
edad	5.66	0.71	7.97	1.80e-15
sexoMujer	-151.99	16.05	-9.47	3.93e-21
est_civilseparado o divorciado	-124.85	30.63	-4.08	4.63e-05
est_civilsoltero	-144.31	21.74	-6.64	3.48e-11
est_civilunido	-63.58	20.98	-3.03	2.45e-03
est_civilviudo	-195.63	64.62	-3.03	2.48e-03

Tabla 4: Estadísticos de Ajuste del Modelo

R-squared	Adj. R-squared	Sigma (Res. Error)	F-statistic	p-value	DF
0.327	0.326	583.12	194.844	0	6407

Modelo 3:

En teoría la instrucción y la experiencia son los motores principales de la productividad, por ende, del salario. Es por esto que elegí las variables educ_cat, horas_trabajo y formal como explicativas del ingreso_ocup.

Summary del Modelo 3:

Tabla 5: Coeficientes del Modelo Propio

Término	Estimación	Error Est.	Estadístico t	p-valor
(Intercept)	-46.63	62.46	-0.75	4.55e-01
educ_catPrimario	100.63	60.96	1.65	9.88e-02
educ_catSecundario	169.45	60.00	2.82	4.76e-03
educ_catSuperior	523.16	61.28	8.54	1.71e-17
horas_trabajo	12.27	0.52	23.68	7.11e-119
formalSi	447.04	17.68	25.28	1.60e-134

Tabla 6: Estadísticos de Ajuste del Modelo

R-squared	Adj. R-squared	Sigma (Res. Error)	F-statistic	p-value	DF
0.248	0.247	616.126	422.677	0	6418

Comparación de los Modelos

Tabla 7: Comparación de Criterios de Selección de Modelos


Modelo	CME	R2Aj	AIC	BIC
Mod AIC	339165.3	0.3273	100059.3	100214.9
Mod BAIC	340028.6	0.3256	100070.6	100192.4
Modelo Propio	379610.7	0.2471	100767.0	100814.4

El modelo `mod_aic` destaca en 3 de los 4 indicadores. Podemos concluir que es el modelo ganador.

Análisis de Residuos.

Cumplimiento de supuestos.

Homocedasticidad




`lm(ingreso_ocup ~ formal + horas_trabajo + educ_cat + region + edad + se`

En el gráfico de residuos vs ajustados, vemos que la varianza de los residuos aumenta con los valores ajustados (forma de abanico). El test de Breusch-Pagan nos da un valor de 146.22 con p-value < 2.2e-16. Se rechaza H_0 .

El modelo presenta **heterocedasticidad**, lo que significa que el error de nuestras predicciones no es constante. El test estadístico confirma que la variabilidad de los ingresos no se explica de igual manera para todos los niveles socioeconómicos.

Normalidad



`lm(ingreso_ocup ~ formal + horas_trabajo + educ_cat + region + edad + se`

Los residuos se desvían fuertemente de la línea teórica, especialmente en la cola derecha con lo cual vemos que no hay normalidad.

El test de Anderson-Darling confirma la ausencia de normalidad.

Independencia de los Errores

Durbin-Watson test

`data: mod_aic`

`DW = 1.8716, p-value = 1.127e-07`

`alternative hypothesis: true autocorrelation is greater than 0`

Durbin-Watson indica que existe autocorrelación positiva leve. El supuesto no se cumple estrictamente, aunque el DW está cerca de 2.

Multicolinealidad

Tabla 8: Factores de Inflación de la Varianza (VIF)

	Variable Predictora	Valor VIF
formal	formal	1.194
horas_trabajo	horas_trabajo	1.051
educ_cat	educ_cat	1.044
region	region	1.007
edad	edad	1.297
sexo	sexo	1.086
est_civil	est_civil	1.049
ant_laboral	ant_laboral	1.047

En general, valores de VIF mayores a 5 se consideran problemáticos. En este caso no tenemos ninguno.

No hay multicolinealidad problemática.

Observaciones Influyentes y Atípicas

Tabla 9: Análisis de puntos influyentes mediante Distancia de Cook


Nro. de Observación (Fila)	Distancia de Cook
3170	0.05054
3838	0.03306
6348	0.02944
1244	0.01475
5129	0.01420
92	0.01335
3883	0.01323
4690	0.01240
1566	0.01148
5641	0.01056

```
top_10_cook$Observacion[1]
```

```
[1] "3170"
```

La Distancia de Cook mide cuánto cambian los coeficientes del modelo cuando se excluye una observación particular. Como se observa en la tabla, para las 10 observaciones con mayor

impacto relativo, el valor máximo alcanzado (el de la observación **3170**) es de **0.05054**. Dado que todos los valores están muy por debajo del umbral crítico de 0.5, podemos concluir que no existen puntos influyentes que estén sesgando los resultados de manera individual. El modelo es estable ante la presencia de estos casos atípicos.



`lm(ingreso_ocup ~ formal + horas_trabajo + educ_cat + region + edad + se`

Interpretación de efectos sobre el ingreso ocupacional.

En la interpretación, cuando analizamos una variable, suponemos que mantenemos todas las demás constantes.

Formalidad laboral:

Ser trabajador formal aumenta el ingreso en \$301 respecto a un trabajador informal. Es significativo ($p < 0.001$).

Horas trabajadas:

Por cada hora adicional trabajada, el ingreso aumenta \$10.69. Es significativo ($p < 0.001$).

Nivel educativo:

- Primario: tener el nivel primaria aumenta \$103 respecto de no tener educación. No es significativo ($p = 0.074$).
- Secundario: tener el nivel secundario aumenta \$238 respecto de no tener educación. Es Significativo ($p < 0.001$).
- Superior: el nivel superior de educación aumenta \$607 respecto de no tener educación. Altamente significativo ($p < 0.001$).

A mayor educación, mayor ingreso.

Región:

Se comparan contra el grupo de referencia “Cuyo.”

- Gran Buenos Aires: pertenecer a esta región aumenta \$139. Es estadísticamente significativo ($p < 0.001$).
- Noreste: pertenecer a esta región aumenta \$138. Es estadísticamente significativo ($p < 0.001$).
- Noroeste: pertenecer a esta región aumenta \$135. Es estadísticamente significativo ($p < 0.001$).
- Pampeana: pertenecer a esta región aumenta \$92. Es estadísticamente significativo ($p < 0.001$).
- Patagonia: pertenecer a esta región aumenta \$372. Es estadísticamente **muy** significativo ($p < 0.001$).

Patagonia tiene el mayor ingreso relativo. Noreste y Noroeste los menores.

Edad

Por cada año adicional de edad, el ingreso aumenta \$4.41, con efecto significativo ($p < 0.001$).

Sexo

Las mujeres tienen en promedio \$152 menos de ingreso que los hombres, efecto altamente significativo ($p < 0.001$).

Estado civil

- Separado/divorciado: ganan \$120 menos que los casados en promedio. Efecto significativo.
- Soltero: ganan \$138 menos que los casados en promedio. Efecto significativo.
- Unido: ganan \$63 menos que los casados en promedio. Efecto significativo.
- Viudo: ganan \$184 menos que los casados en promedio. Efecto significativo.

Todos los estados civiles distintos de casado presentan menor ingreso.

Antigüedad laboral

Ninguna categoría resulta estadísticamente significativa (todos los p-values > 0.05 , salvo “6 meses a 1 año” con $p = 0.098$ marginal). La antigüedad laboral no tiene efecto significativo sobre el ingreso en este modelo.

Ajuste global

El modelo explica el 32.7 % de la variabilidad del ingreso ($R^2_{aj} = 0.327$), siendo globalmente significativo (F-statistic $p < 0.001$).

Consigna II: Regularización y Predicción

Ajustar el modelo mediante Ridge.

El valor óptimo hallado mediante validación cruzada ($k = 5$) es $\lambda \approx 27.10$. Al ser un valor mayor a cero, el algoritmo confirma que aplicar una ligera penalización a los coeficientes ayuda a generalizar mejor el modelo. Esto indica que el modelo original de Mínimos Cuadrados Ordinarios (MCO) tenía una varianza ligeramente elevada que Ridge logra mitigar.

Comparación de Desempeño (MSE): al evaluar ambos modelos con los datos de prueba (test set), observamos que:

- MSE Ridge: 311886.8
- MSE MCO (AIC): 312404.5

La reducción del error cuadrático medio es de aproximadamente un 0.17%.

Ajustar el modelo mediante Lasso.

El valor óptimo hallado mediante validación cruzada ($k = 5$) es $\lambda \approx 0.2098$.

Comparación de Desempeño (MSE): al evaluar ambos modelos con los datos de prueba (test set), observamos que:

- MSE Lasso: 312279.7
- MSE MCO (AIC): 312404.5

Capacidad predictiva.

De acuerdo a los resultados obtenidos, el modelo más adecuado para este ejemplo es la **Regresión Ridge**, el cual tiene el error cuadrático medio más bajo.

Modelo 1 MCO (Selección AIC) - MSE: 312404.5

Modelo 2 Regresión Ridge ($\lambda = 27.10$) - MSE: 311886.8

Modelo 3 Regresión Lasso ($\lambda = 0.21$) - MSE: 312279.7

Consigna III: Regresión Logística

Tabla 10: Razones de Odds (Exp) de Predictores Significativos

	Valor
(Intercept)	0.003
formalSi	5.316
horas_trabajo	1.047
educ_catPrimario	2.033
educ_catSecundario	4.212
educ_catSuperior	10.646
regionGran Buenos Aires	1.613
regionNoreste	0.524
regionNoroeste	0.458
regionPampeana	1.434
regionPatagonia	4.831
edad	1.018
sexoMujer	0.517
est_civilseparado o divorciado	0.644
est_civilsoltero	0.548
est_civilviudo	0.534

	Valor
ant_laboralMas de 5 años	2.171


Razones de odds.

El objetivo de la **razón de odds** es comparar chances de éxito entre 2 grupos diferentes. En la lista anterior, el valor indica cuanto más o menos chances de ganar 1000 o más, tiene el grupo, en comparación con la categoría de referencia (la que no aparece en la lista).

Manteniendo el resto de las variables constantes:

- formalSi: las personas con trabajo formal tienen 5 veces más de chances de ganar a partir de 1000 en comparación con los informales.
- horas_trabajo: por cada hora adicional trabajada, las chances de ganar 1000 o más aumentan un 4.7 %.
- educ_catPrimario: la persona con educación primaria tienen 2 veces más chances de ganar 1000 o más que quienes no tiene educación.
- educ_catSecundario: la persona con educación secundaria tienen 4 veces más chances de ganar 1000 o más que quienes no tiene educación.
- educ_catSuperior: la persona con educación superior tienen 10 veces más chances de ganar 1000 o más que quienes no tiene educación.
- regionGran Buenos Aires: vivir en Gran Buenos Aires multiplica por 1.613 las chances de ganar 1000 o más de 1000 respecto a Cuyo.
- regionPatagonia: vivir en la Patagonia multiplica por 4.8 las chances de éxito respecto a Cuyo. En contraste, el Noroeste (0.458) las reduce a menos de la mitad.
- edad 1.018: por cada año adicional del trabajador, las chances de ganar 1000 o más aumentan un 1.8 %.
- sexoMujer: en este caso tenemos un efecto negativo. Las mujeres tienen un 48.3 % menos de chances ($1 - 0.517 = 0.483$) de superar el umbral de ingresos que los hombres.
- est_civilseparado o divorciado: los divorciados o separados tienen 35.6 % menos de chances de superar o igualar los 1000 que el grupo de referencia.
- ant_laboralMas de 5 años: tener más de 5 años de antigüedad laboral multiplica por 2.1 las chances de igualar o superar los 1000 de ingreso ocupacional.

Curva ROC



Un **AUC de 0.847** indica que tu clasificador tiene un desempeño **muy bueno**. Significa que si seleccionamos al azar a una persona que gana 1000 y a otra que gana menos de 1000, existe un **87.7% de probabilidad** de que el modelo asigne una probabilidad de “éxito” más alta a la persona que realmente gana más.

```
threshold
1  0.359624
```

El punto óptimo donde maximizamos sensibilidad y especificidad es 0.359624.

Usando este punto, sacamos la matriz de confusión:

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	1184	169
1	527	872

Accuracy : 0.7471
95% CI : (0.7304, 0.7632)

No Information Rate : 0.6217
P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.4962

McNemar's Test P-Value : < 2.2e-16

Sensitivity : 0.8377
Specificity : 0.6920
Pos Pred Value : 0.6233
Neg Pred Value : 0.8751
Prevalence : 0.3783
Detection Rate : 0.3169
Detection Prevalence : 0.5084
Balanced Accuracy : 0.7648

'Positive' Class : 1

Exactitud Global: 74.71 %

La precisión global indica que el modelo clasificó correctamente al **74.71 %** de los individuos del conjunto de prueba.

Sensibilidad: 83.77 %

El 83.77 % de los verdaderos positivos (VP) fueron clasificados como tales.

Es la capacidad del modelo para detectar los “éxitos” (personas que ganan más de 1000).

Especificidad: 69.20 %

De todas las personas que tienen ingresos bajos, el modelo identificó correctamente al **69.20 %**.

Valor Predictivo Positivo (VPP): 62.33 %

Cuando el modelo predice un ingreso alto, acierta el **62.33 %** de las veces.

Valor Predictivo Negativo (VPN): 87.51 %

Cuando el modelo predice que alguien tiene ingresos bajos, tiene un **87.51 % de seguridad** de que es verdad.