

TP final de Regresión Avanzada

Martín Ceriotti

2026-04-23

Consigna I: Regresión Lineal

Modelo 1:

Modelo de Selección Automática por Criterio de Información de Akaike (AIC). Se busca equilibrio entre bondad de ajuste y complejidad.

Summary del Modelo 1:

Tabla 1: Coeficientes del Modelo AIC

Término	Estimación	Error Est.	Estadístico t	p-valor
(Intercept)	-31.387	80.120	-0.392	0.695
formalSi	301.373	18.738	16.083	0.000
horas_trabajo	10.685	0.507	21.083	0.000
educ_catPrimario	103.327	57.909	1.784	0.074
educ_catSecundario	237.627	57.295	4.147	0.000
educ_catSuperior	606.553	58.631	10.345	0.000
regionGran Buenos Aires	139.120	31.028	4.484	0.000
regionNoreste	-138.258	35.808	-3.861	0.000
regionNoroeste	-135.490	27.324	-4.959	0.000
regionPampeana	92.236	27.117	3.401	0.001
regionPatagonia	372.126	31.397	11.852	0.000
edad	4.409	0.768	5.745	0.000
sexoMujer	-152.074	16.042	-9.480	0.000
est_civilseparado o divorciado	-119.809	30.625	-3.912	0.000
est_civilsoltero	-137.890	21.782	-6.331	0.000
est_civilunido	-63.006	20.973	-3.004	0.003
est_civilviudo	-183.927	64.599	-2.847	0.004
ant_laborall a 5 años	-23.976	38.658	-0.620	0.535

Término	Estimación	Error Est.	Estadístico t	p-valor
ant_laboral6 meses a 1 año	-81.538	49.308	-1.654	0.098
ant_laboralEntre 3 y 6 meses	-52.459	52.688	-0.996	0.319
ant_laboralMas de 5 años	43.689	39.919	1.094	0.274
ant_laboralMenos de 1 mes	-92.420	84.885	-1.089	0.276

```
# 2. Extraemos las métricas de ajuste con broom::glance()
metrics <- glance(mod_aic) %>%
  dplyr::select(
    `R-squared` = r.squared,
    `Adj. R-squared` = adj.r.squared,
    `Sigma (Res. Error)` = sigma,
    `F-statistic` = statistic,
    `p-value` = p.value,
    `DF` = df.residual
  )
metrics %>%
  kable(digits = 3, caption = "Estadísticos de Ajuste del Modelo") %>%
  kable_styling(
    bootstrap_options = c("striped", "hover", "condensed"),
    latex_options = "hold_position",
  )
```

Tabla 2: Estadísticos de Ajuste del Modelo

R-squared	Adj. R-squared	Sigma (Res. Error)	F-statistic	p-value	DF
0.33	0.327	582.379	149.845	0	6402

Modelo 2:

Modelo de Selección Automática por Criterio de Información Bayesiano (BIC). Este modelo se seleccionó bajo el principio de parsimonia.

Summary del Modelo 2:

Tabla 3: Coeficientes del Modelo BIC

Término	Estimación	Error Est.	Estadístico t	p-valor
(Intercept)	-96.008	72.845	-1.318	0.188
formalSi	325.312	17.701	18.378	0.000
horas_trabajo	10.682	0.507	21.089	0.000
educ_catPrimario	114.441	57.823	1.979	0.048
educ_catSecundario	249.276	57.209	4.357	0.000
educ_catSuperior	618.675	58.515	10.573	0.000
regionGran Buenos Aires	135.205	31.050	4.354	0.000
regionNoreste	-134.968	35.839	-3.766	0.000
regionNoroeste	-134.538	27.352	-4.919	0.000
regionPampeana	89.017	27.131	3.281	0.001
regionPatagonia	370.224	31.425	11.781	0.000
edad	5.661	0.710	7.974	0.000
sexoMujer	-151.990	16.054	-9.468	0.000
est_civilseparado o divorciado	-124.849	30.628	-4.076	0.000
est_civilsoltero	-144.305	21.744	-6.636	0.000
est_civilunido	-63.584	20.978	-3.031	0.002
est_civilviudo	-195.632	64.621	-3.027	0.002

Modelo 3:

En teoría la instrucción y la experiencia son los motores principales de la productividad, por ende, del salario. Es por esto que elegí las variables educ_cat, horas_trabajo y formal como explicativas del ingreso_ocup.

Summary del Modelo 3:

Tabla 4: Coeficientes del Modelo Propio

Término	Estimación	Error Est.	Estadístico t	p-valor
(Intercept)	-46.625	62.464	-0.746	0.455
educ_catPrimario	100.630	60.958	1.651	0.099
educ_catSecundario	169.447	60.003	2.824	0.005
educ_catSuperior	523.156	61.284	8.537	0.000
horas_trabajo	12.274	0.518	23.676	0.000
formalSi	447.041	17.682	25.282	0.000

Comparación de los Modelos

Tabla 5: Comparación de Criterios de Selección de Modelos


Modelo	CME	R2Aj	AIC	BIC
Mod AIC	339165.3	0.3273	100059.3	100214.9
Mod BAIC	340028.6	0.3256	100070.6	100192.4
Modelo Propio	379610.7	0.2471	100767.0	100814.4

El modelo mod_aic destaca en 3 de los 4 indicadores. Podemos concluir que es el modelo ganador.

Análisis de Residuos.

Cumplimiento de supuestos.

Homocedasticidad




`lm(ingreso_ocup ~ formal + horas_trabajo + educ_cat + region + edad + se`

En el gráfico de residuos vs ajustados, vemos que la varianza de los residuos aumenta con los valores ajustados (forma de abanico). El test de Breusch-Pagan nos da un valor de 146.22 con p-value < 2.2e-16. Se rechaza H0.

El modelo presenta **heterocedasticidad**, lo que significa que el error de nuestras predicciones no es constante. El test estadístico confirma que la variabilidad de los ingresos no se explica de igual manera para todos los niveles socioeconómicos; el modelo es más preciso para algunos grupos que para otros.

Normalidad



```
lm(ingreso_ocup ~ formal + horas_trabajo + educ_cat + region + edad + se
```

Los residuos se desvían fuertemente de la línea teórica, especialmente en la cola derecha con lo cual vemos que no hay normalidad.

El test de Anderson-Darling confirma la ausencia de normalidad.

Independencia de los Errores

Durbin-Watson test

```
data: mod_aic
DW = 1.8716, p-value = 1.127e-07
alternative hypothesis: true autocorrelation is greater than 0
```

Durbin-Watson indica que existe autocorrelación positiva leve. El supuesto no se cumple estrictamente, aunque el DW está cerca de 2.

Multicolinealidad

Tabla 6: Factores de Inflación de la Varianza (VIF)

	Variable Predictora	Valor VIF
formal	formal	1.194
horas_trabajo	horas_trabajo	1.051
educ_cat	educ_cat	1.044
region	region	1.007
edad	edad	1.297
sexo	sexo	1.086
est_civil	est_civil	1.049
ant_laboral	ant_laboral	1.047

En general, valores de VIF mayores a 5 se consideran problemáticos. En este caso no tenemos ninguno.

No hay multicolinealidad problemática.

Observaciones Influyentes y Atípicas


Tabla 7: Análisis de puntos influyentes mediante Distancia de Cook

Nro. de Observación (Fila)	Distancia de Cook
3170	0.05054
3838	0.03306
6348	0.02944
1244	0.01475
5129	0.01420
92	0.01335
3883	0.01323
4690	0.01240
1566	0.01148
5641	0.01056

```
top_10_cook$Observacion[1]
```

```
[1] "3170"
```

La Distancia de Cook mide cuánto cambian los coeficientes del modelo cuando se excluye una observación particular. Como se observa en la tabla, para las 10 observaciones con mayor impacto relativo, el valor máximo alcanzado (el de la observación **3170**) es de **0.05054**. Dado que todos los valores están muy por debajo del umbral crítico de 0.5, podemos concluir que no existen puntos influyentes que estén sesgando los resultados de manera individual. El modelo es estable ante la presencia de estos casos atípicos.



$\text{lm}(\text{ingreso_ocup} \sim \text{formal} + \text{horas_trabajo} + \text{educ_cat} + \text{region} + \text{edad} + \text{se})$

Interpretación de efectos sobre el ingreso ocupacional.

Formalidad laboral

Ser trabajador formal aumenta el ingreso en \$301 respecto a un trabajador informal, efecto altamente significativo ($p < 0.001$).

Horas trabajadas

Por cada hora adicional trabajada, el ingreso aumenta \$10.69, efecto altamente significativo ($p < 0.001$).

Nivel educativo

Categoría de referencia: Sin instrucción.

NivelEfectoSignificanciaPrimario+\$103No significativo ($p = 0.074$)Secundario+\$238Significativo ($p < 0.001$)Superior+\$607Altamente significativo ($p < 0.001$)

A mayor educación, mayor ingreso. El nivel primario no es estadísticamente distinto del nivel sin instrucción.

Región

Categoría de referencia: Cuyo.

Región	Efecto	Significancia
Gran Buenos Aires	+\$139	Significativo
Noreste	-\$138	Significativo
Noroeste	-\$135	Significativo
Pampeana	+\$92	Significativo
Patagonia	+\$372	Altamente significativo

Patagonia tiene el mayor ingreso relativo; Noreste y Noroeste los menores.

Edad

Por cada año adicional de edad, el ingreso aumenta \$4.41, efecto significativo ($p < 0.001$).

Sexo

Categoría de referencia: Varón. Las mujeres tienen en promedio \$152 menos de ingreso, efecto altamente significativo ($p < 0.001$).

Estado civil

Categoría de referencia: Casado.

Estado	Efecto	Significancia
Separado/divorciado	-\$120	Significativo
Soltero	-\$138	Altamente significativo
Unido	-\$63	Significativo
Viudo	-\$184	Significativo

Todos los estados civiles distintos de casado presentan menor ingreso.

Antigüedad laboral

Categoría de referencia: Menos de 3 meses.

Ninguna categoría resulta estadísticamente significativa (todos los p-values > 0.05 , salvo “6 meses a 1 año” con $p = 0.098$ marginal). La antigüedad laboral no tiene efecto significativo sobre el ingreso en este modelo.

Ajuste global

El modelo explica el 32.7 % de la variabilidad del ingreso ($R^2_{aj} = 0.327$), siendo globalmente significativo (F-statistic $p < 0.001$).